assignment1 我的答案

xzx

2016 年 12 月 2 日

1 Q1: k-Nearest Neighbor classifier

1.1 cs231n/classifier/k_nearest_neighbor.py

1.1.1 compute_distances_two_loops(self,X)

直接想比较困难，题目给出提示说将其转化为矩阵相乘以及两个和的形式。于是想到将平方和展开。
为方便起见，先用平方距离进行计算，计算完成以后再将其开方。设两个向量为 W 与 V。那么这两个向量的平方距离应该为 $(w_1-v_1)^2+...+(w_n-v_n)^2$ 将起展开，得到 $x_1^2-2x_1y_1+y_1^2+...+x_n^2-2x_ny_n+y_n^2$，继续变形，得：

$$\sum_{i=1}^{n} x_i^2 + \sum_{i=1}^{n} y_i^2 - 2\sum_{i=1}^{n} x_i y_i$$

这个式子的前两项就是题目中说的两个和的形式，后一项就是矩阵相乘的形式.

2 Q2: Training a Support Vector Machine

2.1 cs231n/classifier/linear_svm.py

2.1.1 svm_loss_vectorized(W, X, y, reg)

loss 首先把 loss function 的公式给列出来：$L_i = \sum_{j\neq y_i} max(0, s_j - s_{y_i} + 1)$
不管怎么样，肯定是要知道每一个图片对应的每一类的概率. 先用 $X * W$ 把分数算出来。
然后取出正确的分类的分数，相减.python 中对于矩阵减去向量，如果维数正确的话，它会自动补齐的. 然后再加上 δ，最后把负数全部都变成 0 就好了.

微分 首先不考虑要除以的 num_train。
首先看公式中 s_j 与 s_{y_i} 对 loss 的影响。当 $s_j - s_{y_i} + 1$ 小于 0 的时候，对 loss 是没有影响的。当大于 0 的时候，如果 s_j 变化 1，则 loss 相应的变化 1；如果 s_{y_i} 变化 1，loss 相应的变化-1. 这样，ds 就可以表示出来了.
再来考虑每一个 s_i, j 是怎么来的。假设说 X 是 (N, D) 的矩阵，N 表示数据的个数，D 表示每个数据的维度, W 是 (D, C) 的矩阵，C 表示类型的个数.

$s_{i,j} = X_{[i,:]} * W_{[:,j]}$. 如果 $W_{[t,j]}$ 变化了 1，则 $s_{i,j}$ 相应要变化 $X_{[i,t]}$. 所以，$dW_{t,j}$ 就等于 $ds_{i,j} * X_{i,t}$ ，剩下的就是将起向量化就可以了。下图以 2 维为例，

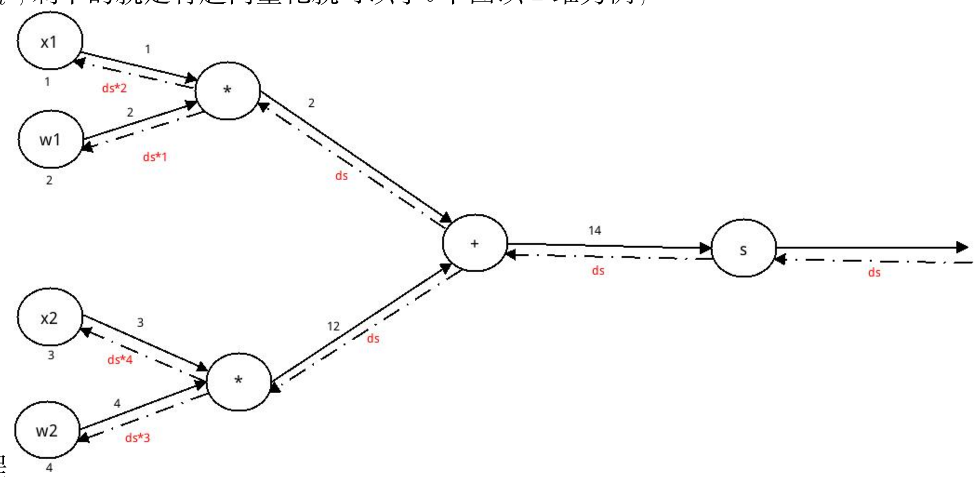

描述了反向传播的过程

当然 W 会对不同的 X 乘很多次。对于 W 不同的分支来说，就是不同位置导数相加就是一个 W 的导数.

2.2 Stochastic Gradient Descent

这个函数没有什么难度，设计这个算法的思路就是因为 Gradient Descent 在大的数据集上太慢了，就用了这么一个函数，每次随机选取几个数据进行 Gradient Descent.

3 Q3: Implement a Softmax classifier

3.1 cs231n/classifiers/softmax.py

3.1.1 softmax_loss

loss 用 X 和前面算出来的 W 算出一个分数。还是假设只有一个数据，那算出来的分数就是这个数据对应的每个类的分数，记为 s_j. 把这个数据分到第 k 类的概率是 $\frac{e^{s_k}}{\sum_j e^{s_j}}$。将正确的标签对应的概率取负对数就是需要的答案.loss 没有什么可说的，反正 naive 跟 vectorized 都一样。

微分 先来看一下 loss 函数对于每一个 s_j 的导数.

假设正确的标记是 y. 损失函数用 L 来表示. 即 $L = -\log \frac{e^{s_y}}{\sum_j e^{s_j}} = -(\log e^{s_y} -$

$\log\sum_j e^{s_j}) = -s_y + \log\sum_j e^{s_j}$.
对 s_y 求导，$\frac{\partial L}{\partial s_y} = -1 + \frac{e^{s_y}}{\sum_j e^{s_j}}$ 对剩下的 s_k 求导，$\frac{\partial L}{\partial s_{k\neq y}} = \frac{e^{s_k}}{\sum_j e^{s_j}}$
这样，ds 就求出来了，剩下的就跟前面 svm 的地方反向传播一样就好了.